

Análisis Predictivo de la Popularidad de Noticias Online con Machine Learning

David Gomez Agudelo, Santiago Trespalacios Bolivar, Juan Diego Duque Jimenez
Programa de Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia

Abstract—This project presents a predictive analysis about online news popularity based on supervised Machine Learning algorithms. The study employs the Online News Popularity dataset from Mashable, which contains over 39,000 articles and 58 features, to anticipate the number of times a news article will be shared before publication. The methodology includes data preprocessing, feature selection, and model training, aiming to support editorial decisions and enhance content visibility.

Keywords: Machine Learning, Prediction, Popularity, News, Digital Media, Data Analysis

En la actualidad, el consumo de noticias ha cambiado completamente. Cada día se generan millones de noticias, artículos e información en noticieros, revistas y medios digitales, por ende, sobresalir a ojos de los lectores es una de las tareas más importantes y difíciles para los escritores.

Las técnicas de Machine Learning se han convertido en herramientas esenciales para lograr comprender por qué una noticia o artículo es más popular o mejor valorada por los usuarios, permitiendo además predecir el comportamiento de las personas con respecto a las publicaciones y contribuir al éxito de las mismas. No se trata solo de escribir buenos textos, sino también de saber cómo, cuándo y dónde publicarlos para conseguir el mayor impacto en el público objetivo.

En este contexto, el presente proyecto tiene como objetivo desarrollar una solución a un problema mediante la aplicación de distintas técnicas de Machine Learning aprendidas en clase, utilizando una base de datos seleccionada como fuente principal de información y previamente autorizada para su uso. El proceso incluye la preparación y la exploración de los datos, la selección de las características más relevantes, el entrenamiento y validación utilizando distintos modelos de aprendizaje automático.

I. DESCRIPCIÓN DEL PROBLEMA

I-A. Contexto del problema y utilidad de la solución

Los medios digitales enfrentan el desafío de llegar a la mayor cantidad de usuarios con sus contenidos, en un panorama donde cada lector selecciona minuciosamente qué noticias consumir. Es por tal razón que, para los medios tanto de comunicación como de blogs de noticias les resulta bastante importante el no solo producir artículos que sean de calidad, sino también el maximizar su alcance, para que pueda llegar a un público más extenso.

En este caso, se mide la popularidad de una noticia, que comúnmente se da por el número de veces que la noticia

es compartida por los medios digitales, resultando ser un indicador clave del impacto y de la viralidad del contenido.

Ante esta necesidad, el desarrollo de una solución basada en Machine Learning para predecir la popularidad de un artículo antes de la publicación del mismo tiene una utilidad práctica que genera un beneficio claro en el campo de los medios de comunicación y de medios digitales. Esto le permitiría a los editores realizar lo siguiente:

Optimizar el contenido: Realizar ajustes en lo que respecta al titular, la longitud del artículo o el uso de imágenes y videos para potenciar su viralidad por medio de las redes sociales.

Mejorar la estrategia de publicación: Decidir el mejor momento o canal de visualización (negocios, tecnología, entretenimiento, etc.) para publicar un artículo y así poder potenciar su visibilidad.

Asignar recursos de marketing: Identificar los artículos que podrían tener un alto potencial de popularidad para promocionarlos de una manera activa y lograr maximizar los ingresos de estos mismos por publicidad.

Llegando al punto de que, el utilizar el sistema predictivo se convierte en una herramienta que da un soporte a las personas con la decisión estratégica que se puede tomar al momento de publicar algún artículo o alguna noticia para competir en los medios digitales y tener un mayor alcance.

I-B. Composición de la base de datos

El dataset [1], es proveniente de la plataforma de noticias de internet llamada Mashable, y este contiene información sobre unos 39,644 artículos publicados durante un periodo de dos años. La base de datos está compuesta por un total de 61 atributos:

Número de muestras: 39,644.

Número de variables: 58 variables predictoras y 1 variable objetivo shares. Dos atributos adicionales url y timedelta son informativos pero no se usarán directamente en la predicción.

Significado de las variables: Las características se pueden agrupar en varias categorías:

- Atributos de contenido: Longitud del título n_tokens_title, longitud del contenido

n_tokens_content, número de enlaces, número de imágenes, etc.

- Atributos lingüísticos: Tasa de palabras únicas rate_unique_tokens, tasa de palabras no triviales rate_non_stop_words, polaridad del sentimiento global_sentiment_polarity, etc.
- Metadatos: Canal de la noticia (entretenimiento, negocios, tecnología, etc.), día de la semana de publicación.
- Popularidad de palabras clave: Medidas promedio, mínima y máxima de la popularidad de las palabras clave asociadas al artículo.

Variable objetivo: *shares*, un valor entero que representa el número de veces que el artículo fue compartido. Esta variable presenta una distribución altamente sesgada hacia la derecha: la mayoría de los artículos reciben pocos compartidos, mientras que un grupo reducido alcanza valores muy elevados. En la Imagen 1 se muestra la distribución en su escala original, donde se evidencia esta fuerte asimetría. Adicionalmente, en la Imagen 2 se presenta la misma distribución utilizando una escala logarítmica, lo que permite visualizar con mayor claridad tanto la concentración de valores bajos como la presencia de valores extremos.

Datos faltantes: El dataset está preprocesado y no contiene valores faltantes, por lo que no se requiere una estrategia de imputación de datos.

Codificación de variables: Las variables categóricas ya han sido codificadas. Los canales de noticias data_channel_is_* y los días de la semana weekday_is_* están representados mediante codificación one-hot. La variable is_weekend es binaria. El resto de las variables son numéricas (enteras o de punto de flotante).




Imagen 1: Distribución de la variable *shares*.

I-C. Paradigma de Aprendizaje

Para este proyecto, se decidió abordar el problema tanto desde el enfoque de regresión como de clasificación, con un énfasis principal en la clasificación binaria. Esta elección se fundamenta en que la distribución de la variable objetivo (*shares*) presenta una marcada asimetría, lo que dificulta la predicción precisa del número exacto de veces que una noticia es compartida. En contraste, formular el problema como una tarea de clasificación definiendo un umbral basado en la




Imagen 2: Distribución de la variable *shares*.

mediana de shares, que distingue entre noticias populares y no populares, ofrece una interpretación más práctica y evita un desbalance extremo de clases, lo que resulta coherente con los objetivos del estudio.

No obstante, también se explora el paradigma de regresión ordinal de manera complementaria, con el fin de analizar el comportamiento en distintos rangos de popularidad y comparar el desempeño de ambos enfoques ya que se definen 5 rangos aproximadamente balanceados. Este análisis se considera más exploratorio y menos central dentro del estudio, resulta crucial para comparar el desempeño entre paradigmas y determinar qué nivel de segmentación ofrece una mejor comprensión sobre la popularidad de los artículos.

II. ESTADO DEL ARTE

Para comprender las soluciones existentes al problema de predecir la popularidad de noticias en línea, se ha realizado una revisión de fuentes especializadas, incluyendo trabajos que utilizan el mismo dataset.

A Proactive Intelligent Decision Support System for Predicting the Popularity of Online News

Este es el artículo original que introduce el dataset. Los autores presentan un Sistema Inteligente de Soporte a la Decisión diseñado para maximizar la popularidad de los artículos antes de ser publicados. Además se plantea un sistema proactivo el cual sugiere cambios fáciles de implementar para mejorar el pronóstico de las noticias.

El Paradigma de aprendizaje se aborda como una tarea de clasificación, para determinar si un artículo será “popular” o no, utilizando un umbral de compartidos, también se explora como un problema de regresión para predecir el número exacto de compartidos, en el proceso se utilizaron cinco modelos de clasificación: Random Forest (RF), Adaptive Boosting (AdaBoost), Máquinas de Vectores de Soporte (SVM), K-Nearest Neighbors (KNN) y Naïve Bayes.

Para la metodología de validación se emplearon ventanas deslizantes (rolling windows). Este enfoque simula un escenario real donde el modelo se reentrena periódicamente con datos nuevos, para así poder evaluar las métricas y teniendo que la métrica principal fue el Área Bajo la Curva ROC (AUC), también se reportaron Exactitud (Accuracy), Precisión y Recall. Para la tarea de regresión, se utilizó el

Error Absoluto Medio (MAE), con esto se obtuvo como resultado que los modelos de ensamble como Random Forest y Gradient Boosting mostraron el mejor rendimiento. En la tarea de clasificación, Random Forest alcanzó una exactitud cercana al 67 %.[2]

Prediction & evaluation of online news popularity using machine intelligence

En este trabajo se utiliza un paradigma de aprendizaje supervisado, específicamente un problema de clasificación binaria. El objetivo es clasificar cada noticia basándose en si supera un umbral predefinido de compartidos.

El Paradigma de aprendizaje se enmarca como un problema de clasificación, haciendo uso de una estrategia central que consiste en aplicar Análisis Discriminante Lineal y posteriormente poner un énfasis especial en los algoritmos de boosting como AdaBoost y LPBoost, cabe destacar que a diferencia de AdaBoost, LPBoost formula el entrenamiento como un problema de optimización lineal cuyo objetivo principal es maximizar el margen del clasificador combinado. comparando el desempeño de estos enfoques híbridos con el popular Random Forest. Además utiliza una metodología de validación conocida como Hold-out para validar el modelo, evaluando su sensibilidad a la partición de los datos mediante siete diferentes proporciones de división entre entrenamiento y prueba.

A pesar de que se reportaron métricas estándar (Exactitud, Precisión, Recall), el F-measure es la métrica clave donde el modelo propuesto demuestra su superioridad. Dando como resultado que la combinación de LDA con AdaBoost superó al resto de modelos, alcanzando un F-measure del 73 % y una exactitud del 69 % [3]

Hyper Parameter Optimization using Genetic Algorithm on Machine Learning Methods for Online News Popularity Prediction

En este artículo, se propone el mejorar la predicción de la popularidad de las noticias mediante la optimización de los modelos de Machine Learning utilizados, esto por medio de algoritmos genéticos en lugar del Grid Search, reduciendo el tiempo y manteniendo la misma precisión.

Fue abordado como problema de clasificación evaluando los modelos: Support Vector Machine (SVM), Random Forest, Adaptive Boosting, K-Nearest Neighbors y Naive Bayes. Además se optimizaron los hiperparámetros usando Genetic Algorithm. Por otro parte, para validar se hizo una división del dataset, una parte de entrenamiento equivalente a un (70 %) y otra de prueba equivalente a un (30 %).

El resultado es evaluado usando la exactitud (accuracy) y el tiempo requerido para buscar los hiperparámetros correctos (tiempo computacional), siendo este el último el más importante. Logrando que la utilización del Algoritmo Genético redujera de una manera significativa el tiempo de cómputo manteniendo una precisión similar a la del Grid Search. En este caso, el mejor modelo fue Random Forest, con una exactitud de un 67 %.[4]

Predicting the Popularity of Online News Using Classification Methods with Feature Filtering Techniques

En este artículo, se analizan diferentes métodos de clasificación para predecir la popularidad de las noticias en línea, buscando identificar cuál es el modelo más preciso y además las características que son más influyentes.

Se aborda como problema de clasificación utilizando los siguientes modelos: Random Forest (RF), Bayes Net (BN), Logistic Function, SimpleCart y C4.5. También se aplicaron técnicas de filtrado de características (InfoGain, Chi-Squared, Correlation, Gain Ratio y OneR) para sacar las 10 mejores. Además de aplicarse un Fold Cross validation de 10 pliegues para todos los modelos evaluados.

El desempeño se midió utilizando métricas estándar. Los resultados concluyeron que Random Forest fue el modelo más robusto, superando a los demás clasificadores. Específicamente, este modelo alcanzó una exactitud del 67.05 %, una precisión de 0.66, un *F-Measure* de 0.69 y un área bajo la curva (AUC) de 0.73, estableciendo estos valores como referencia de rendimiento para el conjunto de datos evaluado.[5]

En conclusión, la literatura sugiere que los modelos basados en ensambles de árboles de decisión (Random Forest, Gradient Boosting, XGBoost, ADAboost) son los más prometedores para este dataset. Además, la selección de características y la transformación del problema a clasificación son estrategias comunes y efectivas.

III. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

III-A. Configuración experimental

III-A1. Metodología de Validación: Se utiliza una Validación Cruzada Estratificada con K-Fold ($k=5$), lo que permite mantener la proporción de clases en cada subconjunto, obtener estimaciones más robustas del desempeño y calcular los intervalos de confianza al 95 %. Este enfoque también ayuda a mitigar el riesgo de sobreajuste durante la optimización. Adicionalmente, la búsqueda de hiperparámetros se ejecuta mediante la utilización de GridSearchCV, incorporando validación cruzada interna para garantizar una selección más confiable de los parámetros óptimos para el modelo.

III-A2. Modelos de Machine Learning: El proceso de experimentación incluye la evaluación de cinco modelos de aprendizaje supervisado seleccionados por su diversidad metodológica y su aplicación frecuente en problemas de clasificación. Esta variedad permite comparar enfoques lineales, basados en distancias, métodos en ensamblado, modelos neuronales y clasificadores de margen máximo, garantizando un análisis robusto del desempeño bajo un mismo esquema de validación.

Número	Modelo
1	Logistic Regression
2	K-Nearest Neighbors
3	Random Forest
4	Red Neuronal
5	Support Vector Machine

Tabla I: Modelos evaluados en el estudio

Adicionalmente, aunque el código implementado permite utilizar tanto un SVM con kernel (SVC) como un SVM lineal (LinearSVC), durante la experimentación se evidencia que el SVM con kernel presenta tiempos de entrenamiento significativamente más altos, especialmente debido al tamaño del conjunto de datos y la dimensionalidad de las características. Por tal razón, para este informe se optó por utilizar únicamente el SVC lineal.

III-A3. Métricas de Desempeño: La evaluación de los modelos se diseñó para abordar los desafíos específicos del conjunto de datos, priorizando la robustez frente al desbalance de clases y la naturaleza jerárquica de la variable objetivo. Si bien se reporta la exactitud (Accuracy) como línea base comparativa, la toma de decisiones se fundamenta en métricas que discriminan la calidad de las predicciones en las clases minoritarias (Precision, Recall y F1-Score).

Adicionalmente, dado que el problema trata con variables ordinales, se incorpora el Error Absoluto Medio (MAE) para cuantificar no solo el error de clasificación, sino la magnitud de la desviación respecto al rango real. El área bajo la curva (ROC-AUC) se utiliza finalmente para medir la capacidad de separación entre clases independientemente del umbral de decisión elegido.

Métrica	Fórmula	Justificación de uso
Accuracy	$\frac{TP+TN}{Total}$	Establece una línea base de comparación global entre modelos.
Precision	$\frac{TP}{TP+FP}$	Crucial para minimizar el costo de los Falsos Positivos en la toma de decisiones.
Recall	$\frac{TP}{TP+FN}$	Necesario para garantizar la cobertura de la clase de interés (minimizar Falsos Negativos).
F1-Score	$\frac{2 \cdot P \cdot R}{P+R}$	Métrica principal para ranking de modelos debido al desbalance de clases y así evitar sesgos de la exactitud.
ROC-AUC	Área bajo curva	Evalúa la robustez del modelo para distinguir clases independientemente del umbral de corte.
MAE (ordinal)	$\frac{1}{n} \sum y_i - \hat{y}_i $	Cuantifica la "distancia" del error, ya que en escalas ordinales el confundir clases lejanas es peor.

Tabla II: Métricas seleccionadas y justificación metodológica

III-B. Resultados del entrenamiento de Modelos

III-B1. Hiperparámetros Analizados: Para optimizar el desempeño de cada modelo, se realizó una búsqueda de hiperparámetros mediante GridSearchCV. Las mallas de hiperparámetros fueron diseñadas considerando un balance entre cobertura exploratoria y eficiencia computacional.

Específicamente, para los modelos lineales y SVM se exploró el parámetro de regularización C en escala logarítmica; para Random Forest se limitó la profundidad y el número de estimadores para evaluar la capacidad de generalización; y en KNN se varió el número de vecinos para ajustar la suavidad de la frontera de decisión.

A continuación, se detalla la configuración de la malla:

Modelo	Hiperparámetros y Valores	Total
Logistic Regression	C: [0.1, 1.0, 10.0, 100.0] penalty: ['l2'] solver: ['lbfgs']	4
K-Nearest Neighbors	n_neighbors: [5, 11, 21] weights: ['distance'] metric: ['euclidean']	3
Random Forest	n_estimators: [100, 200] max_depth: [20, None] min_samples_split: [2, 5] min_samples_leaf: [1, 2]	16
MLP Neural Network	hidden_layer: [(100,), (100, 50)] activation: ['relu'] alpha: [0.001, 0.01] learning_rate: ['adaptive']	4
Support Vector Machine	C: [0.1, 1.0, 10.0] kernel: ['linear']	3

Total de combinaciones evaluadas: 30 (con K-Fold=5)

Tabla III: Espacio de búsqueda de hiperparámetros por modelo

El diseño de estas mallas resultó en un total de 30 configuraciones únicas. Dado que cada una fue evaluada mediante validación cruzada estratificada con $k = 5$, el experimento conllevó la ejecución de 150 procesos de entrenamiento y validación independientes, garantizando así la robustez estadística de los hiperparámetros seleccionados.

III-C. Clasificación Binaria

III-C1. Resultados del entrenamiento: Se implementaron y evaluaron los modelos de aprendizaje supervisado bajo un paradigma de clasificación binaria, donde la variable objetivo representa si un artículo alcanza popularidad alta ($shares \geq mediana$) o baja ($shares < mediana$). Los resultados se reportan en términos de F1-Score como métrica primaria.

Modelo	F1 (CV)	Acc.	F1	AUC
Random Forest	0.6685	0.6601	0.6601	0.7257
Logistic Regression	0.6513	0.6508	0.6507	0.6988
Support Vector Mach.	0.6504	0.6495	0.6493	0.6981
MLP Neural Net.	0.6564	0.6450	0.6450	0.7110
K-Nearest Neighbors	0.6290	0.6311	0.6292	0.6801

Tabla IV: Resumen de Métricas Clave

Análisis de Resultados:

- **Mejor desempeño general:** Random Forest alcanzó el F1-Score más alto (0.6601) y el mejor ROC-AUC (0.7257), demostrando superioridad en la capacidad discriminativa. Esto sugiere que su estructura de ensamblado logra capturar interacciones no lineales entre las 58 características mejor que los modelos individuales.
- **Separación en Grupos de Rendimiento:** Se observa una clara división en el rendimiento. Los modelos lineales (Logistic Regression $F1 = 0,6507$ y SVM Lineal $F1 = 0,6493$) forman un segundo grupo que queda consistentemente rezagado respecto al Random Forest. La diferencia de rendimiento sugiere que, si bien una componente lineal es relevante, la ganancia predictiva real reside en la capacidad de los modelos de ensamble para capturar interacciones y fronteras de decisión no lineales de las características
- **Redes neuronales (MLP):** Aunque obtuvo el segundo mejor AUC (0.7110), su F1-Score (0.6450) cayó ligeramente por debajo de los modelos lineales. Esta discrepancia sugiere que, si bien el modelo ordena bien las probabilidades (buen AUC), el umbral de decisión por defecto podría no ser el óptimo dada la complejidad de los datos y el tamaño de la muestra.
- **K-Nearest Neighbors:** Este fue el modelo con el desempeño más bajo tanto en F1 (0.6292) como en AUC (0.6801). Este resultado es consistente con la sensibilidad de los métodos basados en distancia ante espacios de alta dimensionalidad ("maldición de la dimensionalidad").
- **Consistencia (CV vs Test):** Al comparar las columnas F1 (CV) y F1, se observa que la caída de rendimiento es mínima ($< 0,01$ en la mayoría de casos), lo que indica que los modelos no sufren de sobreajuste y generalizan adecuadamente.

III-C2. Mejores Configuraciones de Hiperparámetros:

La búsqueda mediante GridSearchCV permitió identificar las siguientes configuraciones óptimas para cada modelo:

Modelo	Configuración Óptima
Logistic Regression	$C=100.0$, $\text{penalty}='l2'$, $\text{solver}='lbfgs'$
K-Nearest Neighbors	$n_neighbors=21$, $\text{weights}='distance'$, $\text{metric}='euclidean'$
Random Forest	$n_estimators=200$, $\text{max_depth}=\text{None}$, $\text{min_samples_split}=2$, $\text{min_samples_leaf}=1$
MLP Neural Network	$\text{hidden_layer_sizes}=(100,)$, $\text{activation}='relu'$, $\alpha=0.001$, $\text{learning_rate}='adaptive'$
Support Vector Machine	$C=1.0$, $\text{kernel}='linear'$

Tabla V: Hiperparámetros Óptimos por Modelo (GridSearchCV).

La regresión logística funcionó bien con regularización débil ($C=100.0$), indicando ausencia de sobreajuste y características suficientemente informativas. Random Forest optó por una configuración compleja (200 árboles), lo que mejoró su capacidad predictiva. KNN requirió $k=21$ vecinos, favoreciendo una mayor suavización y menor sensibilidad a valores atípicos. El MLP convergió con una arquitectura simple de una capa y regularización moderada ($\alpha=0.001$). Finalmente, el SVM lineal obtuvo su mejor desempeño con regularización moderada ($C=1.0$) y kernel lineal, señalando que el problema es separable de forma lineal.

III-C3. Matriz de Confusión: Las matrices de confusión permiten visualizar los patrones de error específicos y la distribución de aciertos para cada modelo evaluado en la clasificación binaria.




Imagen 3: Matrices de confusión para los cinco modelos evaluados en clasificación binaria.

Interpretación: La evaluación de las matrices y su diagonal permite encontrar las siguientes interpretaciones:

- Se puede observar que el modelo KNN es el modelo con más falsos negativos, lo cual refleja las dificultades

del modelo para poder separar las clases y concuerda con su bajo nivel de F1-Score.

- Por otro lado, el resto de modelos generan una gráfica similar y concentrados en la diagonal, con patrones de error más controlados y menores al KNN, corroborando que estos poseen un nivel de F1-Score más alto que el anterior y consistente con los valores similares de precisión y recall.

III-C4. Curvas ROC: El análisis de la curva ROC permite evaluar el desempeño discriminativo del modelo más allá de un umbral. Con esta gráfica comparamos la sensibilidad (Verdaderos positivos) y la especificidad (Falsos positivos).




Imagen 4: Curvas ROC para los cinco modelos en clasificación binaria. La línea diagonal discontinua representa clasificación aleatoria (AUC=0.5).

Análisis:

El estudio del área bajo la curva (AUC) nos indica que un valor alto en esta estadística refleja una alta capacidad del modelo para poder diferenciar entre las clases. Se describen los siguientes puntos sobre el desempeño y la capacidad de separación de las clases:

- Los modelos con mayor AUC fueron Random Forest (AUC=0.7257) y MLP (AUC=0.7110), conservando las tasas de verdaderos positivos superiores a comparación de los falsos positivos.
- Todos los modelos superan con diferencia a diagonal (AUC=0.5), lo que refleja la capacidad predictiva de los modelos.

III-D. Regresión Ordinal

Como análisis exploratorio complementario, se implementó un enfoque de regresión ordinal dividiendo la variable *shares* en 5 niveles de popularidad relativamente equilibrados. Este paradigma respeta la naturaleza ordinal inherente del problema y penaliza errores proporcionalmente a su magnitud usando MAE como métrica principal.

Tabla VI: Resultados de Modelos - Regresión Ordinal

Modelo	MAE	Accuracy	Adj. Accuracy
Random Forest	1.2042	0.3270	0.6712
MLP Neural Network	1.2626	0.3196	0.6491
Logistic Regression	1.2857	0.3139	0.6448
K-Nearest Neighbors	1.2865	0.2863	0.6494
Support Vector Machine	1.2937	0.3130	0.6442

Hallazgos clave:

- **MAE reducido:** Random Forest obtuvo el menor MAE (1.2042), siendo el modelo que comete el error promedio más reducido en la predicción del nivel de popularidad. Esto indica una mejor capacidad para aproximarse al orden correcto frente a los demás modelos.
- **Accuracy exacta moderada:** La accuracy estricta (predicción exacta de la clase) se ubicó entre 28.63 % y 32.70 %, lo que confirma que la predicción exacta de un nivel ordinal específico es un desafío considerable debido a la cercanía entre clases y su naturaleza altamente imprecisa.
- **Adjacency Accuracy alta:** Todas las Adjacency Accuracy se ubicaron entre 0.6442 y 0.6712, mostrando que entre el 64 % y 67 % de las predicciones están a ± 1 nivel de la categoría real. Incluso cuando el modelo falla, lo hace “cerca”, lo cual es esencial en problemas ordinales donde los errores cercanos son menos costosos.

III-D1. Mejores Configuraciones de Hiperparámetros:

La búsqueda mediante GridSearchCV identificó las siguientes configuraciones óptimas para los modelos implementados en el paradigma ordinal:

Modelo	Configuración Óptima
Logistic Regression	C=0.1, penalty='l2', solver='lbfgs'
K-Nearest Neighbors	n_neighbors=21, weights='distance', metric='euclidean'
Random Forest	n_estimators=200, max_depth=None, min_samples_split=2, min_samples_leaf=1
MLP Neural Network	hidden_layer_sizes=(100,), activation='relu', alpha=0.001, learning_rate='adaptive'
Support Vector Machine	C=0.1, kernel='linear'

Tabla VII: Hiperparámetros Óptimos por Modelo en Regresión Ordinal (GridSearchCV).

Observaciones sobre las configuraciones:

- Tanto Logistic Regression como SVM seleccionaron una regularización más fuerte (C=0.1) respecto a sus contrapartes binarias. Esto indica que, bajo el esquema ordinal, los modelos lineales requieren controlar más el sobreajuste debido a la mayor variabilidad introducida por las cinco categorías ordenadas.
- Random Forest, KNN y MLP conservaron esencialmente la misma configuración óptima que en clasificación binaria, lo que sugiere que estos modelos no

requieren ajustes estructurales significativos al cambiar de un enfoque dicotómico a uno ordinal.

- La estabilidad de las configuraciones para los modelos no lineales respalda la robustez de sus arquitecturas para capturar relaciones ordinales sin necesidad de mayor regularización o variación en la complejidad.

III-D2. Matriz de Confusión: Las matrices de confusión permiten analizar en detalle cómo cada modelo distribuye sus predicciones entre las cinco categorías ordinales definidas: Muy Bajo, Bajo, Medio, Alto y Muy Alto. Este análisis es fundamental en escenarios ordinales, ya que no solo interesa identificar los errores, sino también evaluar la magnitud del desvío respecto de la clase real.




Imagen 5: Matrices de confusión para los cinco modelos evaluados en clasificación ordinal.

Interpretación: La inspección detallada de las matrices evidencia patrones característicos de la clasificación ordinal:

- Predominancia de aciertos en clases extremas.** Todos los modelos presentan mayor concentración en la diagonal para las clases *Muy Bajo* y *Muy Alto*, lo cual indica que estas categorías son más fáciles de identificar debido a su separación más clara respecto del resto.
- Mayor confusión en categorías intermedias.** Las clases *Bajo*, *Medio* y *Alto* muestran mayor dispersión de predicciones. Esto es consistente con la naturaleza ordinal del problema: los límites entre estas clases son más difusos y los modelos tienden a realizar errores por cercanía (p. ej., predecir Bajo cuando el valor real es Medio).
- Modelos con mayor concentración en la diagonal.** Random Forest y MLP Neural Network exhiben una mayor proporción de aciertos exactos, lo cual coincide

con sus valores superiores de accuracy y MAE más bajos. En particular, Random Forest muestra menor dispersión hacia clases lejanas.

- Errores con estructura ordinal.** En la mayoría de los modelos, los errores se concentran en clases adyacentes, lo que confirma que las predicciones siguen respetando, en general, el orden natural de las categorías. Este patrón es típico y deseable en problemas de clasificación ordinal.
- Modelos con mayor dispersión.** K-Nearest Neighbors presenta una mayor presencia de errores en clases no adyacentes, lo cual explica su menor desempeño comparado con los demás modelos.

III-D3. Análisis de Errores: El análisis de errores permite comprender no solo cuántas predicciones fueron incorrectas, sino también qué tan lejos se desviaron de la categoría real. Dado que la variable objetivo es ordinal, la magnitud del error es tan relevante como su frecuencia. Por ello, se examina la distribución del error definido como la diferencia entre la categoría real y la predicha.




Imagen 6: Gráficas de Análisis detallado de los errores de predicción en las categorías ordinales.

Principales hallazgos:

- Predicciones correctas predominantes.** La proporción de predicciones exactas oscila entre el 28 % y el 33 % según el modelo, con Random Forest y MLP logrando los mejores resultados. Esto confirma una buena capacidad general para identificar correctamente la categoría ordinal.
- Alta concentración en errores de ± 1 categoría.** Más del 64 % de las predicciones en todos los modelos se encuentran dentro de un margen de error de ± 1 clase. Este comportamiento es deseable en clasificación ordi-

nal, pues implica que los modelos tienden a equivocarse hacia clases vecinas, respetando la estructura de orden inherente al problema.

En conjunto, este análisis confirma que los modelos capturan adecuadamente la estructura ordinal del problema, con errores mayoritariamente acotados y de baja severidad.

III-E. Comparación entre Paradigmas

La evaluación simultánea de clasificación binaria y regresión ordinal permite identificar el enfoque más adecuado según los objetivos del problema:

Métrica	Clasificación Binaria	Regresión Ordinal
Métrica Principal	F1-Score: 0.6601	Adj. Acc.: 0.6712
Interpretabilidad	Alta (2 clases)	Moderada (5 niveles)
Granularidad	Baja	Alta
Aplicabilidad Práctica	Decisiones binarias	Análisis detallado

Tabla VIII: Comparación de Paradigmas - Modelo Random Forest

Recomendaciones:

- **Clasificación binaria:** Preferible para sistemas de recomendación o decisiones automatizadas que requieren clasificación clara (publicar/no publicar en portada).
- **Regresión ordinal:** Más adecuada para análisis exploratorio o cuando se requiere cuantificar la magnitud de la popularidad esperada con mayor detalle.
- **Modelo recomendado:** Random Forest demostró el mejor desempeño en ambos paradigmas, siendo la elección robusta independiente del enfoque seleccionado.

IV. REDUCCIÓN DE DIMENSIONALIDAD

Para evaluar si es posible reducir la complejidad del modelo sin sacrificar rendimiento significativo, se implementaron y compararon dos técnicas complementarias de reducción de dimensionalidad: una basada en métodos lineales (PCA) y otra en métodos no lineales (UMAP). El análisis se realizó sobre los dos mejores modelos identificados en la sección de entrenamiento: Random Forest y Logistic Regression. Además, se optó por clasificación binaria porque este esquema permite una evaluación más estable del impacto de la reducción dimensional, evitando la dispersión de clases y los efectos de desbalance presentes en configuraciones multiclase u ordinales.

IV-A. Análisis Individual de Variables

Antes de aplicar técnicas de reducción, se realizó un análisis exhaustivo de la capacidad discriminativa de cada característica mediante dos enfoques complementarios.

IV-A1. Correlación de Pearson: Se calculó la correlación de Pearson entre cada característica y la variable objetivo binaria. Las 10 variables con mayor correlación con la variable objetivo fueron:

Característica	Correlación
kw_avg_avg	0.1645
LDA_02	-0.1597
data_channel_is_world	-0.1555
is_weekend	0.1379
data_channel_is_entertainment	-0.1106
data_channel_is_socmed	0.1103
weekday_is_saturday	0.1030
data_channel_is_tech	0.0951
kw_min_avg	0.0933
num_hrefs	0.0881

Tabla IX: Top 10 variables por correlación absoluta con la variable objetivo

El análisis reveló que las correlaciones son moderadas (ninguna supera 0.18), lo que indica que la popularidad de noticias es un fenómeno multifactorial que no puede explicarse mediante relaciones lineales simples con variables individuales. Por otro lado, la media de correlaciones fue 0.0089 y la mediana 0.0072, confirmando que la mayoría de las variables aportan información de manera conjunta más que individual.

IV-A2. Análisis de Varianza (ANOVA F-statistic): Se aplicó el test ANOVA F-statistic para medir la capacidad discriminativa de cada variable. De las 58 características originales, 47 resultaron estadísticamente significativas ($p < 0.05$), representando aproximadamente el 81.0 % del total.

Este resultado confirma que la gran mayoría de las características del dataset aportan información relevante para la clasificación, justificando la necesidad de métodos de reducción de dimensionalidad que preserven la información distribuida en múltiples variables.

IV-B. Reducción Lineal: Análisis de Componentes Principales (PCA)

IV-B1. Determinación del Número de Componentes: Se aplicó PCA con el objetivo de proyectar los datos en un espacio de menor dimensión, preservando la mayor cantidad posible de varianza. El análisis de varianza explicada acumulada mostró los siguientes puntos de corte relevantes:

Varianza Explicada	Componentes	Reducción
80 %	23	60.3 %
85 %	26	55.2 %
90 %	30	48.3 %
95 %	36	37.9 %
99 %	45	22.4 %

Tabla X: Componentes necesarios para diferentes niveles de varianza explicada

Se seleccionó un umbral del 90 % de varianza explicada, que requiere 30 componentes (48.3 % de reducción). Este umbral es ampliamente aceptado, ya que permite capturar los patrones principales sin incorporar ruido excesivo y, al mismo tiempo, lograr una reducción sustancial de dimensionalidad.

IV-B2. *Resultados con PCA*: Los dos mejores modelos (Random Forest y Logistic Regression) fueron reentrenados utilizando los 30 componentes principales. Los resultados se muestran en la Tabla XI.

Modelo	Método	Features	F1-Score	Δ F1
Random Forest	Original	58	0.6601	
	PCA	30	0.6391	-0.021
Logistic Reg	Original	58	0.6507	
	PCA	30	0.6365	-0.0142

Tabla XI: Comparación de rendimiento: Datos originales vs PCA

Análisis de resultados:

- **Random Forest**: Experimentó una reducción mínima en F1-Score de -3.18 %, alcanzando 0.6391 con PCA frente a 0.6601 original. Esta degradación marginal es notable dado que se redujo la dimensionalidad en 48.3 %.
- **Logistic Regression**: Mostró aún mayor robustez, con solo -2.18 % de pérdida en F1-Score (0.6365 vs 0.6507). Este comportamiento es consistente con la naturaleza lineal del modelo, que se beneficia de la transformación lineal de PCA.

IV-C. Reducción No Lineal: UMAP

IV-C1. *Determinación del Número de Componentes y Configuración*: Se configuró UMAP para proyectar los datos en 30 dimensiones, el mismo número de componentes seleccionado para PCA, lo que permite una comparación directa entre métodos lineales y no lineales. Esta reducción representa aproximadamente un 48.3 % de disminución de dimensionalidad.

Los valores específicos de los hiperparámetros utilizados incluyen: $n_neighbors = 15$ (balance entre estructura local y global), $min_dist = 0.1$ (distribución estándar de puntos) y $metric = euclidean$ (distancia estándar). Estos valores se adoptaron como configuración estándar

A diferencia de PCA, UMAP puede capturar relaciones no lineales en los datos mediante técnicas de aprendizaje de variedades (manifold learning), permitiendo una representación más rica de estructuras complejas.

IV-C2. *Resultados con UMAP*: Los modelos previamente seleccionados (Random Forest y Logistic Regression) fueron reentrenados utilizando los 30 componentes de UMAP. Los resultados se muestran en la Tabla XII.

Modelo	Método	Features	F1-Score	Δ F1
Random Forest	Original	58	0.6601	
	UMAP	30	0.6117	-0.0484
Logistic Regression	Original	58	0.6507	
	UMAP	30	0.5817	-0.0690

Tabla XII: Comparación de rendimiento: Datos originales vs UMAP

Análisis de resultados:

- **Random Forest**: El F1-Score disminuyó en -0.0484 (aproximadamente un -7.33 %), mostrando que la reducción no lineal afecta más el modelo que PCA, aunque aún mantiene un rendimiento aceptable.
- **Logistic Regression**: Presentó una caída más significativa de -0.0690 (aproximadamente un -10.6 %), consistente con la naturaleza lineal del modelo que no se beneficia tanto de representaciones no lineales.

IV-D. Comparación Final y Recomendaciones

La Tabla XIII presenta una síntesis comparativa de ambos métodos de reducción de dimensionalidad.

Modelo	Original	PCA	UMAP
<i>Random Forest</i>			
F1-Score	0.6601	0.6391	0.6116
Pérdida relativa		-3.18 %	-7.33 %
<i>Logistic Regression</i>			
F1-Score	0.6507	0.6365	0.5817
Pérdida relativa		-2.18 %	-10.6 %

Tabla XIII: Comparación de métodos de reducción de dimensionalidad

V. CONCLUSIONES Y RECOMENDACIONES

V-A. Síntesis de Hallazgos Principales

Este estudio desarrolló y evaluó modelos de Machine Learning para predecir la popularidad de noticias online utilizando el dataset de Mashable, con 39,644 artículos y 58 características. Los principales hallazgos son:

1. **Superioridad de Random Forest**: El modelo Random Forest demostró el mejor desempeño general, alcanzando F1-Score de 0.6601 y ROC-AUC de 0.7257 en clasificación binaria, y MAE de 1.2042 en regresión ordinal. Su capacidad para modelar relaciones no lineales y manejar características heterogéneas lo posiciona como la mejor opción para este problema.
2. **Consistencia con literatura previa**: Los resultados obtenidos (F1-Score: 0.6601, Accuracy: 66.01 %, AUC-ROC: 0.7257) son consistentes con investigaciones previas sobre el mismo dataset. Fernandes et al. (2015) [2] reportaron 67 % de Accuracy con Random Forest, similar a nuestro valor (66.01 %), y un AUC comparable. Wicaksono y Supianto (2018) [4] lograron 67 % de Accuracy usando optimización de hiperparámetros mediante algoritmos genéticos, confirmando la convergencia hacia este rango predictivo. Obiedat (2020) [5] alcanzó F1=0.69 y AUC=0.73 aplicando filtrado de características; la cercanía con nuestros resultados valida la robustez del modelo sin prefiltrado. Deshpande (2017) [3] reportó métricas superiores (Accuracy 69 %, F-measure 73 %) usando LDA y AdaBoost, diferencias atribuibles a metodologías distintas.

La convergencia de resultados entre estudios hacia 66-67 % de Accuracy sugiere un *límite predictivo* en la

predicción de popularidad de noticias online, reflejando que aproximadamente un 30-35 % de la variabilidad depende de factores contextuales impredecibles.

3. **Clasificación binaria vs. regresión ordinal:** La clasificación binaria (alto/bajo engagement) ofrece mayor interpretabilidad y F1-Score más alto, siendo preferible para decisiones divididas. La regresión ordinal (5 niveles) proporciona granularidad adicional con Adjacency Accuracy de 67 %, útil cuando los errores adyacentes son tolerables.

V-B. Contribuciones del Estudio

- **Evaluación comparativa dual:** A diferencia de estudios previos enfocados exclusivamente en clasificación binaria, este estudio contribuye metodológicamente al implementar un paradigma de regresión ordinal de 5 niveles (Muy Bajo a Muy Alto), obteniendo MAE=1.2042 y Adjacency Accuracy=67.12 %, demostrando que es posible agregar granularidad sin sacrificar el desempeño, lo que ofrece mayor flexibilidad para análisis exploratorios.
- **Análisis de importancia de características:** Se identificaron y priorizaron las características más influyentes, ofreciendo guías prácticas para editores y creadores de contenido.
- **Validación rigurosa:** La implementación de Stratified K-Fold Cross-Validation (k=5) con GridSearchCV garantizó estimaciones robustas y minimizó el riesgo de sobreajuste.

V-C. Lecciones Aprendidas

- **Complejidad del fenómeno viral:** La popularidad de noticias online es un fenómeno multifactorial con límites inherentes de predictibilidad. Factores externos impredecibles siempre introducirán variabilidad no modelable.
- **Balance interpretabilidad-complejidad:** Random Forest ofreció el mejor balance entre poder predictivo e interpretabilidad mediante feature importance, mientras que redes neuronales más complejas (MLP) no lograron mejoras significativas con el tamaño de dataset disponible.
- **Relevancia de la evaluación multimétrica:** Combinar F1-Score, ROC-AUC, Accuracy y Adjacency Accuracy proporcionó una visión holística del desempeño, evitando optimizaciones sesgadas hacia una sola métrica.

V-D. Reflexión Final

Este proyecto demostró que el Machine Learning puede proporcionar herramientas valiosas para comprender y predecir la popularidad de contenido digital, alcanzando niveles de accuracy comparables al estado del arte (66-67 %). Sin embargo, también evidenció las limitaciones inherentes al problema: la viralidad online está influenciada por factores contextuales impredecibles que escapan al alcance de modelos puramente estadísticos.

La verdadera utilidad de estos modelos radica en su capacidad para ofrecer *guías probabilísticas* que informen decisiones editoriales estratégicas, no en reemplazar el criterio humano. Editores armados con predicciones de engagement pueden optimizar recursos, priorizar contenido prometedor y experimentar con estrategias basadas en evidencia empírica.

En última instancia, el éxito de un artículo seguirá dependiendo de una combinación de análisis datos, creatividad editorial y, en cierta medida, del factor impredecible de la serendipia digital. El Machine Learning no elimina la incertidumbre, pero la reduce a niveles manejables para la toma de decisiones informadas.

REFERENCIAS

- [1] K. Fernandes, P. Vinagre, and P. Cortez, "Online News Popularity Data Set," UCI Machine Learning Repository, 2015, doi: 10.24432/C5G01C. [Online]. Available: <https://archive.ics.uci.edu/dataset/332/online+news+popularity>
- [2] K. Fernandes, P. Vinagre, and P. Cortez, "A Proactive Intelligent Decision Support System for Predicting the Popularity of Online News," *University of Minho, Department of Information Systems*, 2015. [Online]. Available: <https://repositorium.uminho.pt/server/api/core/bitstreams/06251279-8d1a-46f8-bbb3-92697a2b3eae/content>
- [3] D. Deshpande, "Prediction & evaluation of online news popularity using machine intelligence," in *Proc. 2017 Int. Conf. on Computing, Communication, Control and Automation (ICCUBEA)*, 2017, pp. 1–6, doi: 10.1109/ICCUBEA.2017.8463790. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/8463790>
- [4] A. S. Wicaksono and A. A. Supianto, "Hyper Parameter Optimization using Genetic Algorithm on Machine Learning Methods for Online News Popularity Prediction," *International Journal of Advanced Computer Science and Applications*, vol. 9, no. 12, pp. 263–267, 2018, doi: 10.14569/IJACSA.2018.091238. [Online]. Available: <https://www.proquest.com/openview/23c86ce1492c42f05d5f554186843ef7/1?pq-origsite=gscholar&cbl=5444811>
- [5] R. Obiedat, "Predicting the Popularity of Online News Using Classification Methods with Feature Filtering Techniques," *Journal of Theoretical and Applied Information Technology*, vol. 98, no. 8, pp. 1163–1172, Apr. 2020. [Online]. Available: <https://www.jatit.org/volumes/Vol98No8/4Vol98No8.pdf>